Řešení příkladu 1

- *N* = 3
- ullet tf_i term frequency of term t in document d_i
- df_t document frequency of term t
- $idf_t = log_{10}(rac{N}{df_t})$ inverted document frequency of term t
- ullet tfq term frequency of term t in query

Intermediate results

term	tf1	tf2	tf3	tfq	df	idf
Plzeň	1	0	1	0	2	0.17609
je	2	1	2	0	3	0
krásné	2	0	1	1	2	0.17609
město	1	0	1	1	2	0,17609
a	1	0	0	0	1	0.47712
to	1	0	0	0	1	0.47712
místo	1	1	0	0	2	0,17609
Ostrava	0	1	0	0	1	0.47712
ošklivé	0	1	0	0	1	0.47712
Praha	0	0	1	0	1	0.47712
také	0	0	1	0	1	0.47712
hezčí	0	0	1	0	1	0.47712

TF-IDF weights

+ $w_i = (1 + log_{10} \; tf_i) * idf_t$ - tf-idf weight of term t in document i

term	w1	w2	w3	q
Plzeň	0.17609	0	0.17609	0
je	0	0	0	0
krásné	0.22910	0	0.17609	0.17609
město	0.17609	0	0.17609	0.17609
a	0.47712	0	0	0
to	0.47712	0	0	0
místo	0.17609	0.17609	0	0
Ostrava	0	0.47712	0	0
ošklivé	0	0.47712	0	0
Praha	0	0	0.47712	0
také	0	0	0.47712	0

Řešení příkladu 1 1

term	w1	w2	w3	q
hezčí	0	0	0.47712	0

Normalized weights

•
$$||w_i||_2 = \sqrt{\sum w_{ij}^2}$$

vector	norm
w1	0,77511
w2	0,69735
w3	0,88088
q	0,24903

Weights

term	w1	w2	w3	q
Plzeň	0.22718	0	0,19990	0
je	0	0	0	0
krásné	0.29557	0	0,19990	0,70710
město	0.22718	0	0,19990	0,70710
a	0.61555	0	0	0
to	0.61555	0	0	0
místo	0.22718	0,25251	0	0
Ostrava	0	0,68419	0	0
ošklivé	0	0,68419	0	0
Praha	0	0	0,54164	0
také	0	0	0,54164	0
hezčí	0	0	0,54164	0

Cosine similiarity

$$ullet$$
 $cos(ec{q},ec{d})=rac{ec{q}*ec{d}}{|ec{q}|*|ec{d}|}=rac{\sum q_id_i}{\sqrt{\sum q_i^2}*\sqrt{\sum d_i^2}}=\sum q_i*d_i$ (normalized)

• q - krásné město

•
$$cos(\vec{q}, \vec{d_1}) = 0,70710*0,29557+0,70710*0,22718 = 0,36964$$
 \checkmark

•
$$cos(\vec{q}, \vec{d_2}) = 0,70710*0+0,70710*0=0$$

-
$$cos(\vec{q}, \vec{d_3}) = 0,70710*0,19990+0,70710*0,19990=0,28270$$

K dotazu q_1 je nejrelevantnější dokument d_1 .

Řešení příkladu 1

2